

Business Intelligence na Formula 1: Conceção de um Data Warehouse para Análise de Performance em Corrida

Estudante 1 (n.º xxxxxxxx) · Estudante 2 (n.º xxxxxxxx) · Estudante 3 (n.º xxxxxxxx)
Mestrado em Ciência de Dados — Business Intelligence, 2025/2026
Escola Superior de Tecnologia e Gestão, Politécnico de Leiria

Resumo — Este relatório documenta as fases de conceção de uma solução de *Business Intelligence* aplicada ao domínio da Formula 1, desenvolvida no âmbito da unidade curricular de Business Intelligence. São apresentados os objetivos do projeto, os promotores e requisitos levantados junto de *stakeholders* simulados, as dez questões de análise que orientam a solução, o estudo das fontes de dados originais e respetivos metadados, e a conceção do modelo dimensional em esquema em estrela (constelação de factos), incluindo a matriz de mapeamento entre as fontes de origem e o *data warehouse* de destino. O modelo proposto integra dados históricos de 77 épocas (1950–2026), dados de incidentes de corrida e telemetria recente, suportando análises de estratégia de paragens, fiabilidade mecânica, consistência de pilotos e impacto do *Safety Car*.

Palavras-chave — Business Intelligence; Data Warehouse; Modelo Dimensional; Star Schema; ETL; Formula 1.

1. Introdução

A Formula 1 é um dos desportos mais orientados a dados do mundo: cada fim de semana de Grande Prémio gera milhões de pontos de dados de cronometragem, telemetria, meteorologia e decisões estratégicas. Este projeto propõe a construção de uma solução completa de *Business Intelligence* (BI) sobre dados históricos e recentes da Formula 1, percorrendo todas as etapas de um projeto de BI: levantamento de requisitos, estudo das fontes e metadados, conceção do modelo dimensional, implementação e refrescamento do *data warehouse* (DW), análise de dados em *dashboards* e narração da história dos dados.

O presente relatório foca as três primeiras fases do projeto: a **conceção** (Secção 2), o **estudo das fontes de dados origem e dos seus metadados** (Secção 3) e a **conceção e desenvolvimento do modelo dimensional** (Secção 4). As fases de integração de dados (ETL), análise e *storytelling* serão documentadas em secções subsequentes do relatório final.

2. Conceção do Projeto

2.1. Objetivos

O objetivo geral é desenvolver uma solução de BI que consolide dados históricos de corridas, pilotos, construtores e circuitos de Formula 1, para responder a questões estratégicas e de performance sobre o desporto. Definem-se quatro objetivos específicos:

- Construir um *data warehouse* dimensional (esquema em estrela) a partir de fontes OLTP históricas;

- Implementar *pipelines* ETL para extração, transformação e carga dos dados, com refrescamento incremental;
- Desenvolver *dashboards* analíticos para apoio à decisão de equipas e analistas;
- Produzir uma narrativa de dados (*storytelling*) intitulada “A Anatomia de uma Vitória”, dirigida a uma plateia-alvo.

2.2. Promotores e Stakeholders

Papel	Entidade / Foco
Promotor académico	UC de Business Intelligence, Mestrado em Ciência de Dados
Sponsor do projeto	Direção de Desporto Motorizado da FIA / equipas de F1 (<i>stakeholder</i> simulado)
Diretor Técnico	Fiabilidade e performance mecânica
Estrategista de Corrida Chefe	Estratégias de paragens e degradação de pneus
Analista de Dados Sénior	Métricas de consistência e ultrapassagens
Utilizadores-alvo	Estrategistas de corrida, analistas de performance, jornalistas especializados e comentadores técnicos

2.3. Levantamento de Requisitos

Os requisitos foram levantados através de análise documental do desporto (regulamentos FIA, relatórios técnicos de época), da exploração dos *datasets* históricos disponíveis e de entrevistas simuladas com três perfis de *stakeholders* típicos de uma equipa de F1 (Diretor Técnico, Estrategista de Corrida Chefe e Analista de Dados Sénior), complementadas com o perfil de Jornalista Especializado/Comentador Técnico para a vertente de narrativa.

Requisitos de negócio. As entrevistas revelaram três necessidades prioritárias: comparação direta de performance entre equipas; previsão de degradação de pneus por circuito; e avaliação de custo-benefício dos investimentos técnicos.

Requisitos técnicos. Fontes em formato CSV e JSON (dados históricos, incidentes e telemetria); ETL em Python (pandas) com orquestração em SQL Server Integration Services (SSIS); armazenamento em SQL Server; visualização em Power BI; modelo dimensional em esquema em estrela; refrescamento incremental agendado nas 24 horas após cada Grande Prémio.

Requisitos de qualidade. Validação de integridade referencial entre factos e dimensões; monitorização de duplicados nas tabelas de dimensão (por chave de negócio); registo de métricas de qualidade do carregamento (linhas carregadas e rejeitadas) para auditoria.

2.4. Questões de Análise

Definiram-se dez questões de análise, alinhadas com os objetivos de negócio, que a solução deve responder:

1. Qual é a evolução histórica do tempo médio de *pit stop* por construtor ao longo das épocas?

2. Existe correlação direta entre a posição de qualificação (*pole position*) e a vitória final na corrida em circuitos de diferente altitude?
3. Quais os construtores com maior taxa de abandono por falha mecânica em condições de temperatura elevada?
4. Como varia a consistência de tempos por volta de um piloto quando este transita de pneus macios para duros?
5. Qual o impacto estatístico da entrada do *Safety Car* na alteração das posições finais do Top 10?
6. Em que setor da volta (S1, S2 ou S3) ocorrem mais ultrapassagens em cada circuito?
7. Qual é a distribuição geográfica dos pontos conquistados por nacionalidade de pilotos nos últimos 20 anos?
8. Que pilotos apresentam maior ganho líquido de posições na primeira volta da corrida a partir de posições intermédias da grelha (P10–P15)?
9. Qual é a eficácia de estratégias de *undercut* vs. *overcut* com base no desgaste real dos pneus?
10. Qual o impacto do número de paragens nas boxes (estratégia de 2 vs. 3 *stops*) na posição final do piloto?

2.5. Entrevistas Diligenciadas e User Stories

Das entrevistas simuladas resultaram onze *user stories*, que ligam cada questão de análise a um perfil de utilizador e a um benefício de negócio concreto.

Diretor Técnico (fiabilidade e performance mecânica):

- *US1* — Como Diretor Técnico, quero comparar o tempo de *pit stop* da minha equipa com os concorrentes diretos, para identificar janelas de otimização mecânica.
- *US2* — Como Diretor Técnico, quero analisar a taxa de abandono por falha mecânica em condições de temperatura elevada, para avaliar a robustez do motor e dos sistemas do carro.

Estrategista de Corrida Chefe (estratégia de paragens e pneus):

- *US3* — Como Estrategista de Corrida, quero simular o impacto de janelas de paragem com base no histórico de degradação de pneu por circuito, para mitigar o risco de perda de posição em pista.
- *US4* — Como Estrategista de Corrida, quero comparar a eficácia de estratégias de *undercut* vs. *overcut* em cada circuito, para maximizar o ganho de posições nas paragens.
- *US5* — Como Estrategista de Corrida, quero avaliar o impacto do número de paragens (2 vs. 3 *stops*) na posição final do piloto, para definir a estratégia ótima para cada corrida.

Analista de Dados Sênior (consistência e ultrapassagens):

- *US6* — Como Analista de Dados Sênior, quero analisar a consistência de tempos por volta de um piloto quando transita de pneus macios para duros, para avaliar a adaptabilidade e gestão de pneus.
- *US7* — Como Analista de Dados Sênior, quero identificar os pilotos com maior ganho líquido de posições na primeira volta a partir de posições intermédias da grelha (P10–P15), para detetar talentos em equipas de meio do pelotão.

- *US8* — Como Analista de Dados Sênior, quero correlacionar a *pole position* com a vitória final, segmentado por altitude do circuito, para entender a vantagem competitiva da qualificação em diferentes tipos de circuito.

Jornalista Especializado / Comentador Técnico (narrativa e contexto):

- *US9* — Como Jornalista Especializado, quero visualizar a distribuição geográfica dos pontos conquistados por nacionalidade de pilotos nos últimos 20 anos, para identificar tendências e hegemonias regionais no desporto.
- *US10* — Como Comentador Técnico, quero analisar o impacto da entrada do *Safety Car* nas posições finais do Top 10, para explicar ao público reviravoltas inesperadas nos resultados.
- *US11* — Como Comentador Técnico, quero identificar o setor da volta (S1, S2 ou S3) com mais ultrapassagens em cada circuito, para enriquecer a narração em tempo real durante as transmissões.

3. Estudo das Fontes de Dados Origem e Metadados

3.1. Inventário das Fontes

O repositório de dados do projeto contém **22 fontes**, organizadas em três categorias: dados tabulares históricos (14 ficheiros CSV, derivados da base de dados Ergast/Kaggle de Formula 1), dados de incidentes e segurança (5 ficheiros CSV/JSON) e dados de telemetria e sessão (estrutura hierárquica de ficheiros JSON por época/Grande Prémio/sessão, 2024–2026).

Tabela 1 — Dados tabulares históricos (CSV)

Ficheiro	Linhas	Chave primária	Período
circuits	78	circuitId	—
constructor_results	12 931	constructorResult sId	1958–2026
constructor_standings	13 697	constructorStand ingsId	1958–2026
constructors	214	constructorId	—
driver_standings	35 493	driverStandingsI d	1950–2026
drivers	865	driverId	—
lap_times	872 521	raceId+driverId+ lap	1996–2026
pit_stops	22 335	raceId+driverId+ stop	2011–2026
qualifying	11 102	qualifyId	2003–2026
races	1 171	raceId	1950–2026
results	27 370	resultId	1950–2026
seasons	77	year	1950–2026
sprint_results	546	resultId	2021–2026

Ficheiro	Linhas	Chave primária	Período
status	140	statusId	—

Tabela 2 — Dados de incidentes e segurança

Ficheiro	Registos	Conteúdo
safety_cars.csv	370	Intervenções de <i>Safety Car</i> (1973–2024)
red_flags.csv	99	Interrupções por bandeira vermelha (1950–2024)
fatal_accidents_drivers.csv	51	Acidentes fatais com pilotos (1952–2015)
fatal_accidents_marshall.csv	5	Acidentes fatais com comissários (1963–2001)
virtual_safety_car_estimates.json	78	Voltas estimadas sob VSC por GP (2015–2024)

Dados de telemetria e sessão. Organizados em diretórios {ano}/{Grande Prémio}/{Sessão}/, cobrindo as épocas de 2024 (25 GP), 2025 (25 GP) e 2026 (9 GP até à data), com cinco sessões por GP (P1, P2, P3, Qualificação e Corrida). Cada sessão contém: corners.json (metadados das curvas), drivers.json (pilotos participantes), rcm.json (mensagens da direção de prova), session_laptimes.json (tempos de volta agregados), weather.json (temperatura do ar e da pista, humidade, vento) e, por piloto, laptimes.json (tempo de volta, composto de pneu, *stint* e tempos de setor S1/S2/S3) e {n}_tel.json (telemetria de alta frequência: velocidade, rpm, acelerador, travão, mudança, DRS e coordenadas GPS).

3.2. Modelo de Dados das Fontes Originais

As fontes tabulares seguem um modelo relacional normalizado, centrado na entidade *raças*, da qual dependem as tabelas transacionais de resultados, tempos de volta, paragens e qualificação. As entidades de referência (*drivers*, *constructors*, *circuits*, *status*, *seasons*) são partilhadas pelas tabelas transacionais. A Figura 1 apresenta o modelo simplificado, incluindo as fontes complementares de incidentes e telemetria.




Figura 1 — Modelo de dados das fontes originais (simplificado).

Tabela 3 — Relações de chave estrangeira nas fontes tabulares

Tabela	Coluna(s) FK	Referencia
racess	circuitId	circuits
results	raceId, driverId, constructorId, statusId	racess, drivers, constructors, status
sprint_results	raceId, driverId, constructorId, statusId	racess, drivers, constructors, status
lap_times	raceId, driverId	racess, drivers
pit_stops	raceId, driverId	racess, drivers
qualifying	raceId, driverId, constructorId	racess, drivers, constructors
constructor_results	raceId, constructorId	racess, constructors
constructor_standings	raceId, constructorId	racess, constructors
driver_standings	raceId, driverId	racess, drivers

As fontes de incidentes (safety_cars, red_flags) não possuem chaves estrangeiras formais: a ligação a racess faz-se por *matching* textual do nome do Grande Prémio e do ano, regra tratada no processo de ETL.

3.3. Metadados das Fontes Principais

Apresentam-se os metadados das tabelas diretamente envolvidas no modelo dimensional. Os metadados completos das 22 fontes constam do documento de estudo de fontes em anexo ao projeto.

Tabela 4 — circuits (78 registos)

Coluna	Tipo	Chave	Nulidade	Descrição
circuitId	INTEGER	PK	NOT NULL	Identificador do circuito
circuitRef	VARCHAR(50)	—	NOT NULL	Referência textual (ex.: albert_park)
name	VARCHAR(100)	—	NOT NULL	Nome oficial
location	VARCHAR(100)	—	NULL	Cidade
country	VARCHAR(50)	—	NULL	País (35 países distintos)
lat, lng	DECIMAL(10,6)	—	NULL	Coordenadas geográficas
alt	INTEGER	—	NULL	Altitude (metros)
url	VARCHAR(255)	—	NULL	URL da Wikipedia

Tabela 5 — drivers (865 registros)

Coluna	Tipo	Chave	Nulidade	Descrição
driverId	INTEGER	PK	NOT NULL	Identificador do piloto
driverRef	VARCHAR(50)	—	NOT NULL	Referência textual
number	INTEGER	—	NULL	Número do carro
code	VARCHAR(3)	—	NULL	Código de 3 letras (HAM, VER)
forename, surname	VARCHAR(50)	—	NOT NULL	Nome e apelido
dob	DATE	—	NULL	Data de nascimento
nationality	VARCHAR(50)	—	NULL	Nacionalidad e
url	VARCHAR(255)	—	NULL	URL da Wikipedia

Tabela 6 — constructors (214 registros)

Coluna	Tipo	Chave	Nulidade	Descrição
constructorId	INTEGER	PK	NOT NULL	Identificador do construtor
constructorRef	VARCHAR(50)	—	NOT NULL	Referência

Coluna	Tipo	Chave	Nulidade	Descrição
				textual
name	VARCHAR(100)	—	NOT NULL	Nome oficial da equipa
nationality	VARCHAR(50)	—	NULL	País de origem
url	VARCHAR(255)	—	NULL	URL da Wikipedia

Tabela 7 — races (1 171 registos, 1950–2026)

Coluna	Tipo	Chave	Nulidade	Descrição
raceId	INTEGER	PK	NOT NULL	Identificador da corrida
year	INTEGER	FK	NOT NULL	Época (→ seasons)
round	INTEGER	—	NOT NULL	Ronda da época
circuitId	INTEGER	FK	NOT NULL	Circuito (→ circuits)
name	VARCHAR(100)	—	NOT NULL	Nome do Grande Prémio
date, time	DATE, TIME	—	NOT NULL / NULL	Data e hora da corrida
fp1..fp3_date/time	DATE, TIME	—	NULL	Datas/horas dos treinos livres
quali_date/time	DATE, TIME	—	NULL	Data/hora da qualificação
sprint_date/time	DATE, TIME	—	NULL	Data/hora da <i>sprint</i>

Tabela 8 — results (27 370 registos, 1950–2026)

Coluna	Tipo	Chave	Nulidade	Descrição
resultId	INTEGER	PK	NOT NULL	Identificador do resultado
raceId, driverId, constructorId	INTEGER	FK	NOT NULL	Corrida, piloto, construtor
grid	INTEGER	—	NOT NULL	Posição de partida
position	INTEGER	—	NULL	Posição final (NULL se não classificado)
positionText	VARCHAR(10)	—	NOT NULL	“1”, “R”, “DNF”, “W”, etc.

Coluna	Tipo	Chave	Nulidade	Descrição
positionOrder	INTEGER	—	NOT NULL	Ordem de classificação numérica
points	DECIMAL(8,2)	—	NOT NULL	Pontos conquistados
laps	INTEGER	—	NOT NULL	Volta completadas
time, milliseconds	VARCHAR(30), INTEGER	—	NULL	Tempo total de corrida
fastestLap, rank, fastestLapTime, fastestLapSpeed	vários	—	NULL	Dados da volta mais rápida
statusId	INTEGER	FK	NOT NULL	Estado de término (→ status)

Tabela 9 — lap_times (872 521 registos, 1996–2026)

Coluna	Tipo	Chave	Nulidade	Descrição
raceId, driverId, lap	INTEGER	PK composta	NOT NULL	Corrida, piloto, volta
position	INTEGER	—	NOT NULL	Posição do piloto nessa volta
time, milliseconds	VARCHAR(20), INTEGER	—	NULL	Tempo da volta

Tabela 10 — pit_stops (22 335 registos, 2011–2026)

Coluna	Tipo	Chave	Nulidade	Descrição
raceId, driverId, stop	INTEGER	PK composta	NOT NULL	Corrida, piloto, n.º da paragem
lap	INTEGER	—	NOT NULL	Volta da paragem
time	TIME	—	NOT NULL	Hora da paragem
duration, milliseconds	DECIMAL(8,3), INTEGER	—	NOT NULL	Duração da paragem

Tabela 11 — qualifying (11 102 registos, 2003–2026)

Coluna	Tipo	Chave	Nulidade	Descrição
qualifyId	INTEGER	PK	NOT NULL	Identificador
raceId, driverId, constructorId	INTEGER	FK	NOT NULL	Corrida, piloto, construtor
position	INTEGER	—	NOT NULL	Posição de qualificação
q1, q2, q3	VARCHAR(20)	—	NULL	Melhores tempos por sessão

Tabela 12 — status (140 registros)

Coluna	Tipo	Chave	Nulidade	Descrição
statusId	INTEGER	PK	NOT NULL	Identificador do estado
status	VARCHAR(10 0)	—	NOT NULL	Descrição (Finished, Engine, Collision, +1 Lap, ...)

A tabela status permite classificar os términos em famílias: classificado (Finished, +N Laps), falha mecânica (Engine, Gearbox, Transmission, Hydraulics, Electrical, ...), acidente (Accident, Collision, Spun off) e exclusão (Disqualified, Withdrew). Esta classificação é a base da medida de abandono mecânico (Secção 4).

Fontes de incidentes. safety_cars regista, por intervenção: GP, causa (Accident: 191; Stranded car: 86; Rain: 28; Debris: 25; outras), volta de ativação e recolha e voltas completas sob SC. red_flags regista a volta da interrupção, se a corrida foi retomada e a descrição do incidente. Os ficheiros de acidentes fatais e o virtual_safety_car_estimates.json complementam a análise de segurança.

Telemetria por piloto. O ficheiro laptimes.json de cada piloto fornece, por volta: tempo, composto de pneu (SOFT, MEDIUM, HARD, INTERMEDIATE, WET), número de *stint*, tempos e velocidades médias de setor (S1/S2/S3). O weather.json fornece séries temporais de temperatura da pista e do ar, humidade e vento por sessão.

3.4. Qualidade dos Dados e Cobertura Temporal

A exploração das fontes identificou as seguintes características relevantes para o ETL:

- **Nulidades semânticas:** em results, os campos position, time e milliseconds são NULL quando o piloto não classifica; o campo positionText codifica o motivo (“R”, “DNF”, “W”, “N”);
- **Chaves compostas:** lap_times e pit_stops não têm chave própria, exigindo chaves compostas e *joins* com races e drivers;
- **Ligações sem chave:** safety_cars.Race e red_flags.Race ligam-se a races.name apenas por *matching* textual (ano + nome do GP);

- **Inconsistência geográfica:** `circuits.country` contém “USA” e “United States” como valores distintos, exigindo normalização;
- **Telemetria posicional:** `session_laptimes.json` contém *arrays* densos sem identificadores explícitos de piloto/volta, exigindo *parsing* posicional;
- **Cobertura temporal heterogênea:** nem todas as fontes cobrem todo o período histórico (Tabela 13), o que delimita o âmbito temporal de cada questão de análise.

Tabela 13 — Cobertura temporal das fontes

Fonte	Início	Fim	Cobertura
seasons, races, results, driver_standings	1950	2026	Completa
constructors, constructor_*	1958	2026	Completa
lap_times	1996	2026	Parcial
qualifying	2003	2026	Parcial
pit_stops	2011	2026	Parcial
sprint_results	2021	2026	Parcial
Telemetria, meteorologia, compostos	2024	2026	Apenas épocas recentes
safety_cars	1973	2024	Histórico
red_flags	1950	2024	Histórico

4. Conceção e Desenvolvimento do Modelo Dimensional

4.1. Assunto de Análise, Factos e Medidas

O assunto de análise central é a **Performance em Corrida**. Para suportar as dez questões de análise são necessários dois níveis de granularidade, pelo que o modelo adota uma **constelação de factos** com duas tabelas de factos que partilham as dimensões conformadas:

- **Fact_Performance** — granularidade: *uma linha por piloto, por corrida*. Suporta análises de resultados, pontos, paragens agregadas e fiabilidade (Questões 1, 2, 3, 5, 7 e 10);
- **Fact_Volta** — granularidade: *uma linha por piloto, por corrida, por volta*. Suporta análises de consistência, degradação de pneus, setores, primeira volta e *Safety Car* (Questões 4, 5, 6, 8 e 9).

Tabela 14 — Medidas por tabela de factos

Facto	Medida	Tipo	Definição
Fact_Performance	Pontos_Conquistados	Aditiva	Pontos do piloto na corrida

Facto	Medida	Tipo	Definição
Fact_Performance	Tempo_Total_Pit_Stops	Aditiva	Soma das durações das paragens do piloto na corrida
Fact_Performance	Num_Pit_Stops	Aditiva	Número de paragens do piloto na corrida
Fact_Performance	Posicoes_Ganhas	Aditiva	Posicao_Partida – Posicao_Final (positivo = ganho)
Fact_Performance	Posicao_Partida, Posicao_Final	Não aditivas	Posições na grelha e à chegada
Fact_Performance	Abandono_Mecanico	Aditiva (contagem)	1 se status ∈ famílias de falha mecânica; 0 caso contrário
Fact_Volta	Tempo_Volta_ms	Não aditiva (médias/desvios)	Tempo da volta em milissegundos
Fact_Volta	Tempo_S1/S2/S3	Não aditivas	Tempos de setor (2024+)
Fact_Volta	Posicao_na_Volta	Não aditiva	Posição do piloto no final da volta
Fact_Volta	Volta_Sob_SC	Aditiva (contagem)	1 se a volta decorreu sob <i>Safety Car</i> /VSC
Fact_Volta	Paragem_Box	Aditiva (contagem)	1 se o piloto parou nas boxes nessa volta

O requisito mínimo do enunciado (um assunto de análise com pelo menos duas medidas) é cumprido e excedido.

4.2. Dimensões, Atributos e Hierarquias

O modelo possui **cinco dimensões**, duas delas com hierarquias explícitas, cumprindo o requisito mínimo (quatro dimensões, duas com hierarquias):

Tabela 15 — Dimensões do modelo

Dimensão	Atributos principais	Hierarquia	SCD
Dim_Tempo	Data, Ano, Trimestre, Mes, Dia, Dia_Semana	Ano → Trimestre → Mês → Dia	Tipo 0
Dim_Piloto	Nome_Completo, Nacionalidade, Data_Nascimento, Equipa, Data_Inicio, Data_Fim	—	Tipo 2 (Equipa)
Dim_Circuito	Nome_Circuito,	Continente → País	Tipo 1

Dimensão	Atributos principais	Hierarquia	SCD
	Cidade, País, Continente, Altitude	→ Cidade → Circuito	
Dim_Construtor	Nome, País, Motorizador	—	Tipo 1
Dim_Composto	Composto, Tipo_Piso	—	Tipo 0

Notas de desenho:

- **Dim_Tempo** tem granularidade ao nível do dia (requisito obrigatório do enunciado), com chave de substituição *Data_SK* no formato *YYYYMMDD*, povoada por geração de calendário para todo o período 1950–2026;
- **Dim_Piloto** aplica **SCD Tipo 2** ao atributo *Equipa*, com intervalos de vigência (*Data_Inicio/Data_Fim*), preservando o histórico de mudanças de equipa. A ligação direta do facto a *Dim_Construtor* mantém-se para análises por equipa independentes do piloto; o atributo *Equipa* em *Dim_Piloto* serve análises *head-to-head* entre companheiros de equipa;
- **Dim_Circuito** inclui o atributo **Altitude** (proveniente de *circuits.alt*), indispensável à Questão 2, e o atributo derivado *Continente*, obtido por *lookup* geográfica com normalização prévia do país (“USA” → “United States”);
- **Dim_Composto** classifica os compostos de pneu (SOFT, MEDIUM, HARD, INTERMEDIATE, WET) por tipo de piso (seco/chuva), suportando as Questões 4 e 9; nas voltas anteriores a 2024 (sem dados de composto), a FK aponta para o membro “Desconhecido”;
- As restantes dimensões aplicam SCD Tipo 0 (atributos estáticos) ou Tipo 1 (sobrescrita), conforme a natureza dos atributos.

4.3. Diagrama do Modelo Dimensional

A Figura 2 apresenta o diagrama do modelo dimensional. *Race_ID*, *Num_Volta* e *Stint* são tratados como dimensões degeneradas, permitindo agrupar voltas por corrida e por *stint* sem necessidade de dimensões adicionais.




Figura 2 — Modelo dimensional: constelação de factos com dimensões conformadas.

4.4. Matriz de Mapeamento Origem → Destino

Tabela 16 — Matriz de mapeamento entre fontes de origem e o data warehouse

Origem (tabela.coluna)	Destino (tabela.coluna)	Transformação / Regra de negócio
racers.date	Dim_Tempo.Data_SK	DATE → inteiro YYYYMMDD; calendário gerado para 1950–2026
racers.date	Dim_Tempo.Ano/ Trimestre/Mes/Dia/ Dia_Semana	Extração YEAR/QUARTER/MONTH /DAY/WEEKDAY
drivers.forename + surname	Dim_Piloto.Nome_Completo	Concatenação com espaço
drivers.nationality	Dim_Piloto.Nacionalidade	Direto
drivers.dob	Dim_Piloto.Data_Nascimento	Direto
results.constructorId → constructors.name	Dim_Piloto.Equipa	Lookup; SCD Tipo 2 com Data_Inicio/Data_Fim na mudança de equipa
circuits.name	Dim_Circuito.Nome_Circuito	Direto
circuits.location	Dim_Circuito.Cidade	Direto
circuits.country	Dim_Circuito.Pais	Normalização (“USA” → “United States”)

Origem (tabela.coluna)	Destino (tabela.coluna)	Transformação / Regra de negócio
circuits.country	Dim_Circuito.Continente	<i>Lookup</i> geográfica país → continente
circuits.alt	Dim_Circuito.Altitude	Direto; NULL → -1 (desconhecida)
constructors.name	Dim_Construtor.Nome	Direto
constructors.nationality	Dim_Construtor.Pais	Direto
constructors.name	Dim_Construtor.Motorizador	<i>Lookup</i> de motorizador (ex.: McLaren → Mercedes)
telemetria laptimes.compound	Dim_Composto.Composto	Distinct; + membro “Desconhecido”
results.raceId → races.date	Fact_Performance.Data_SK	<i>Join</i> e conversão YYYYMMDD
results.driverId/ constructorId	Fact_Performance.Piloto_SK/Construtor_SK	<i>Lookup</i> de chaves de substituição (versão SCD2 vigente à data)
races.circuitId	Fact_Performance.Circuito_SK	<i>Lookup</i>
results.points	Fact_Performance.Pontos_Conquistados	Direto
pit_stops.duration	Fact_Performance.Tempo_Total_Pit_Stops	SUM por (raceId, driverId); NULL antes de 2011
pit_stops.stop	Fact_Performance.Num_Pit_Stops	COUNT por (raceId, driverId); NULL antes de 2011
results.grid	Fact_Performance.Posicao_Partida	Direto
results.position	Fact_Performance.Posicao_Final	Direto; NULL = não classificado
results.grid – results.position	Fact_Performance.Posicoes_Ganhas	grid – position; NULL se não classificado
results.statusId → status.status	Fact_Performance.Abando_no_Mecanico	1 se status ∈ {Engine, Gearbox, Transmission, Hydraulics, Electrical, ...}
lap_times.milliseconds	Fact_Volta.Tempo_Volta_ms	Direto (1996+)
lap_times.position	Fact_Volta.Posicao_na_Volta	Direto
telemetria laptimes.s1/s2/s3	Fact_Volta.Tempo_S1/S2/S3	<i>Matching</i> por código de piloto e volta (2024+)
telemetria laptimes.compound/stint	Fact_Volta.Composto_SK/	<i>Lookup</i> ; “Desconhecido” antes de 2024

Origem (tabela.coluna)	Destino (tabela.coluna)	Transformação / Regra de negócio
	Stint	
safety_cars.Deployed–Retreated + VSC	Fact_Volta.Volta_Sob_SC	<i>Matching</i> textual (ano + nome GP); 1 se volta ∈ intervalo SC/VSC
pit_stops.lap	Fact_Volta.Paragem_Box	1 se existe paragem nessa volta

4.5. Cobertura das Questões de Análise pelo Modelo

A Tabela 17 valida que cada questão de análise é respondível pelo modelo, identificando as estruturas usadas e o âmbito temporal aplicável (decorrente da cobertura das fontes, Tabela 13).

Tabela 17 — Rastreabilidade questões → modelo dimensional

Q	Estruturas do modelo	Âmbito temporal
1	Fact_Performance (Tempo_Total_Pit_Stops, Num_Pit_Stops) × Dim_Construtor × Dim_Tempo	2011+
2	Fact_Performance (Posicao_Partida, Posicao_Final) × Dim_Circuito.Altitude	1950+
3	Fact_Performance (Abandono_Mecanico) × Dim_Construtor × meteorologia (telemetria)	2024+ (temperatura); 1950+ (abandonos)
4	Fact_Volta (Tempo_Volta_ms, desvio- padrão por <i>stint</i>) × Dim_Composto	2024+
5	Fact_Volta (Volta_Sob_SC) + Fact_Performance (posições Top 10)	1973+
6	Fact_Volta (Posicao_na_Volta, Tempo_S1/S2/S3) × Dim_Circuito	2024+ (proxy: variações de posição entre voltas associadas ao setor com maior diferencial)
7	Fact_Performance (Pontos_Conquistados) × Dim_Piloto.Nacionalidade × Dim_Tempo	2006–2026

Q	Estruturas do modelo	Âmbito temporal
8	Fact_Volta (Posicao_na_Volta, volta 1) vs. Fact_Performance.Posi cao_Partida	1996+
9	Fact_Volta (Tempo_Volta_ms por stint/composto, Paragem_Box)	2024+
10	Fact_Performance (Num_Pit_Stops, Posicao_Final)	2011+

Assinala-se uma limitação metodológica na Questão 6: as fontes não registam ultrapassagens por setor de forma direta, pelo que a análise usará um *proxy* — mudanças de posição entre voltas consecutivas, atribuídas ao setor com maior diferencial de tempo — devidamente documentado nos *dashboards*.

4.6. Decisões de Desenho e Justificações

- **Constelação vs. estrela única.** Uma única tabela de factos ao grão piloto×corrida não responderia às questões de consistência por volta, pneus e *Safety Car* (Q4, Q5, Q6, Q8, Q9). A constelação com dimensões conformadas mantém a simplicidade da estrela em cada assunto e garante consistência entre análises (*drill-across*);
- **Dimensões degeneradas.** Race_ID, Num_Volta e Stint ficam no facto, evitando dimensões artificiais sem atributos descritivos;
- **Esquema em estrela (não floco de neve).** As hierarquias (Tempo, Circuito) são desnormalizadas nas dimensões, privilegiando a performance de consulta e a usabilidade em Power BI;
- **Medidas semi-aditivas e contagens.** Posições e tempos de volta não são somáveis; as análises usam médias, medianas e desvios-padrão. Flags binárias (Abandono_Mecanico, Volta_Sob_SC, Paragem_Box) permitem taxas por simples agregação;
- **Volumetria estimada.** Fact_Performance $\approx$ 27 mil linhas; Fact_Volta $\approx$ 873 mil linhas — volumes confortáveis para SQL Server e Power BI em modo *import*;
- **Refrescamento.** O modelo foi desenhado para carga incremental: novos registos identificados por *race.date* posterior à última data carregada e pelos identificadores incrementais *raceId/resultId*, com refrescamento agendado nas 24 h após cada GP.

5. Conclusão e Trabalho Futuro

Este relatório documentou a conceção do projeto de BI sobre Formula 1: os objetivos e requisitos, as dez questões de análise ancoradas em *user stories* de quatro perfis de *stakeholders*, o estudo detalhado das 22 fontes de dados e dos seus metadados, e o modelo dimensional em constelação de factos com cinco dimensões conformadas — cumprindo e excedendo as exigências mínimas do enunciado (dimensão data ao nível do dia, um assunto de análise com pelo menos duas medidas e quatro dimensões com duas hierarquias).

O trabalho futuro inclui: a implementação física do DW em SQL Server; o desenvolvimento do projeto de integração (ETL) em Python/SSIS com as regras de transformação da matriz de mapeamento e o controlo de qualidade definido; a construção dos *dashboards* analíticos em Power BI (painel executivo de construtores, painel de performance do piloto e painel de análise de circuitos); e a preparação da narrativa “A Anatomia de uma Vitória” para a prova oral.

Referências

1. Enunciado do Projeto, UC de Business Intelligence, Mestrado em Ciência de Dados, ESTG — Politécnico de Leiria, 2025/2026.
2. Ergast Developer API — Formula 1 historical database. <http://ergast.com/mrd/>
3. Formula 1 World Championship (1950–2024), Kaggle Datasets. <https://www.kaggle.com/datasets>
4. R. Kimball e M. Ross, *The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling*, 3.^a ed., Wiley, 2013.
5. FIA — Fédération Internationale de l’Automobile, Regulamentos Desportivos e Técnicos de Formula 1. <https://www.fia.com>